AI-ИМПУЛЬС 2.0 · ТРЕК 1 · ПАО «ГАЗПРОМ НЕФТЬ» · КОМАНДА «S21»

Корпоративный AI-ассистент: непрерывность процессов в новой среде

от 20 минут поиска по документам – к 12 секундам точного ответа

139
PDF-руководств

16 825
страниц

17
платформ

ПРОБЛЕМА

Одно сокращение — разные смыслы

WAL — **write access level**

ЛИНТЕР

метка уровня доступа при записи данных

WAL — **write ahead log**

Tarantool

журнал упреждающей записи



17 продуктов — 17 словарей

Сокращения расшифрованы один раз, в глоссарии или при первом упоминании, и разбросаны по 16 825 страницам.



Люди пишут не по словарю

«в СУДИРе», «БДшка», «SNPM» вместо SNMP — живой запрос не совпадает с формой в документе.



Обычная LLM угадывает

Модель расшифровывает сокращение по общим знаниям и выбирает не тот смысл — ответ звучит уверенно, но неверен.

РЕШЕНИЕ

Сначала понимаем термины, потом ищем и отвечаем

1

Словарь из PDF

Автоматически извлекаем пары «аббревиатура — расшифровка» с цитатой и страницей

2

Распознавание

Находим сокращения в вопросе: падежи, суффиксы, опечатка, кириллица/латиница

3

Выбор значения

По продукту, действию и словам вопроса; при неоднозначности — уточнение

4

Гибридный поиск

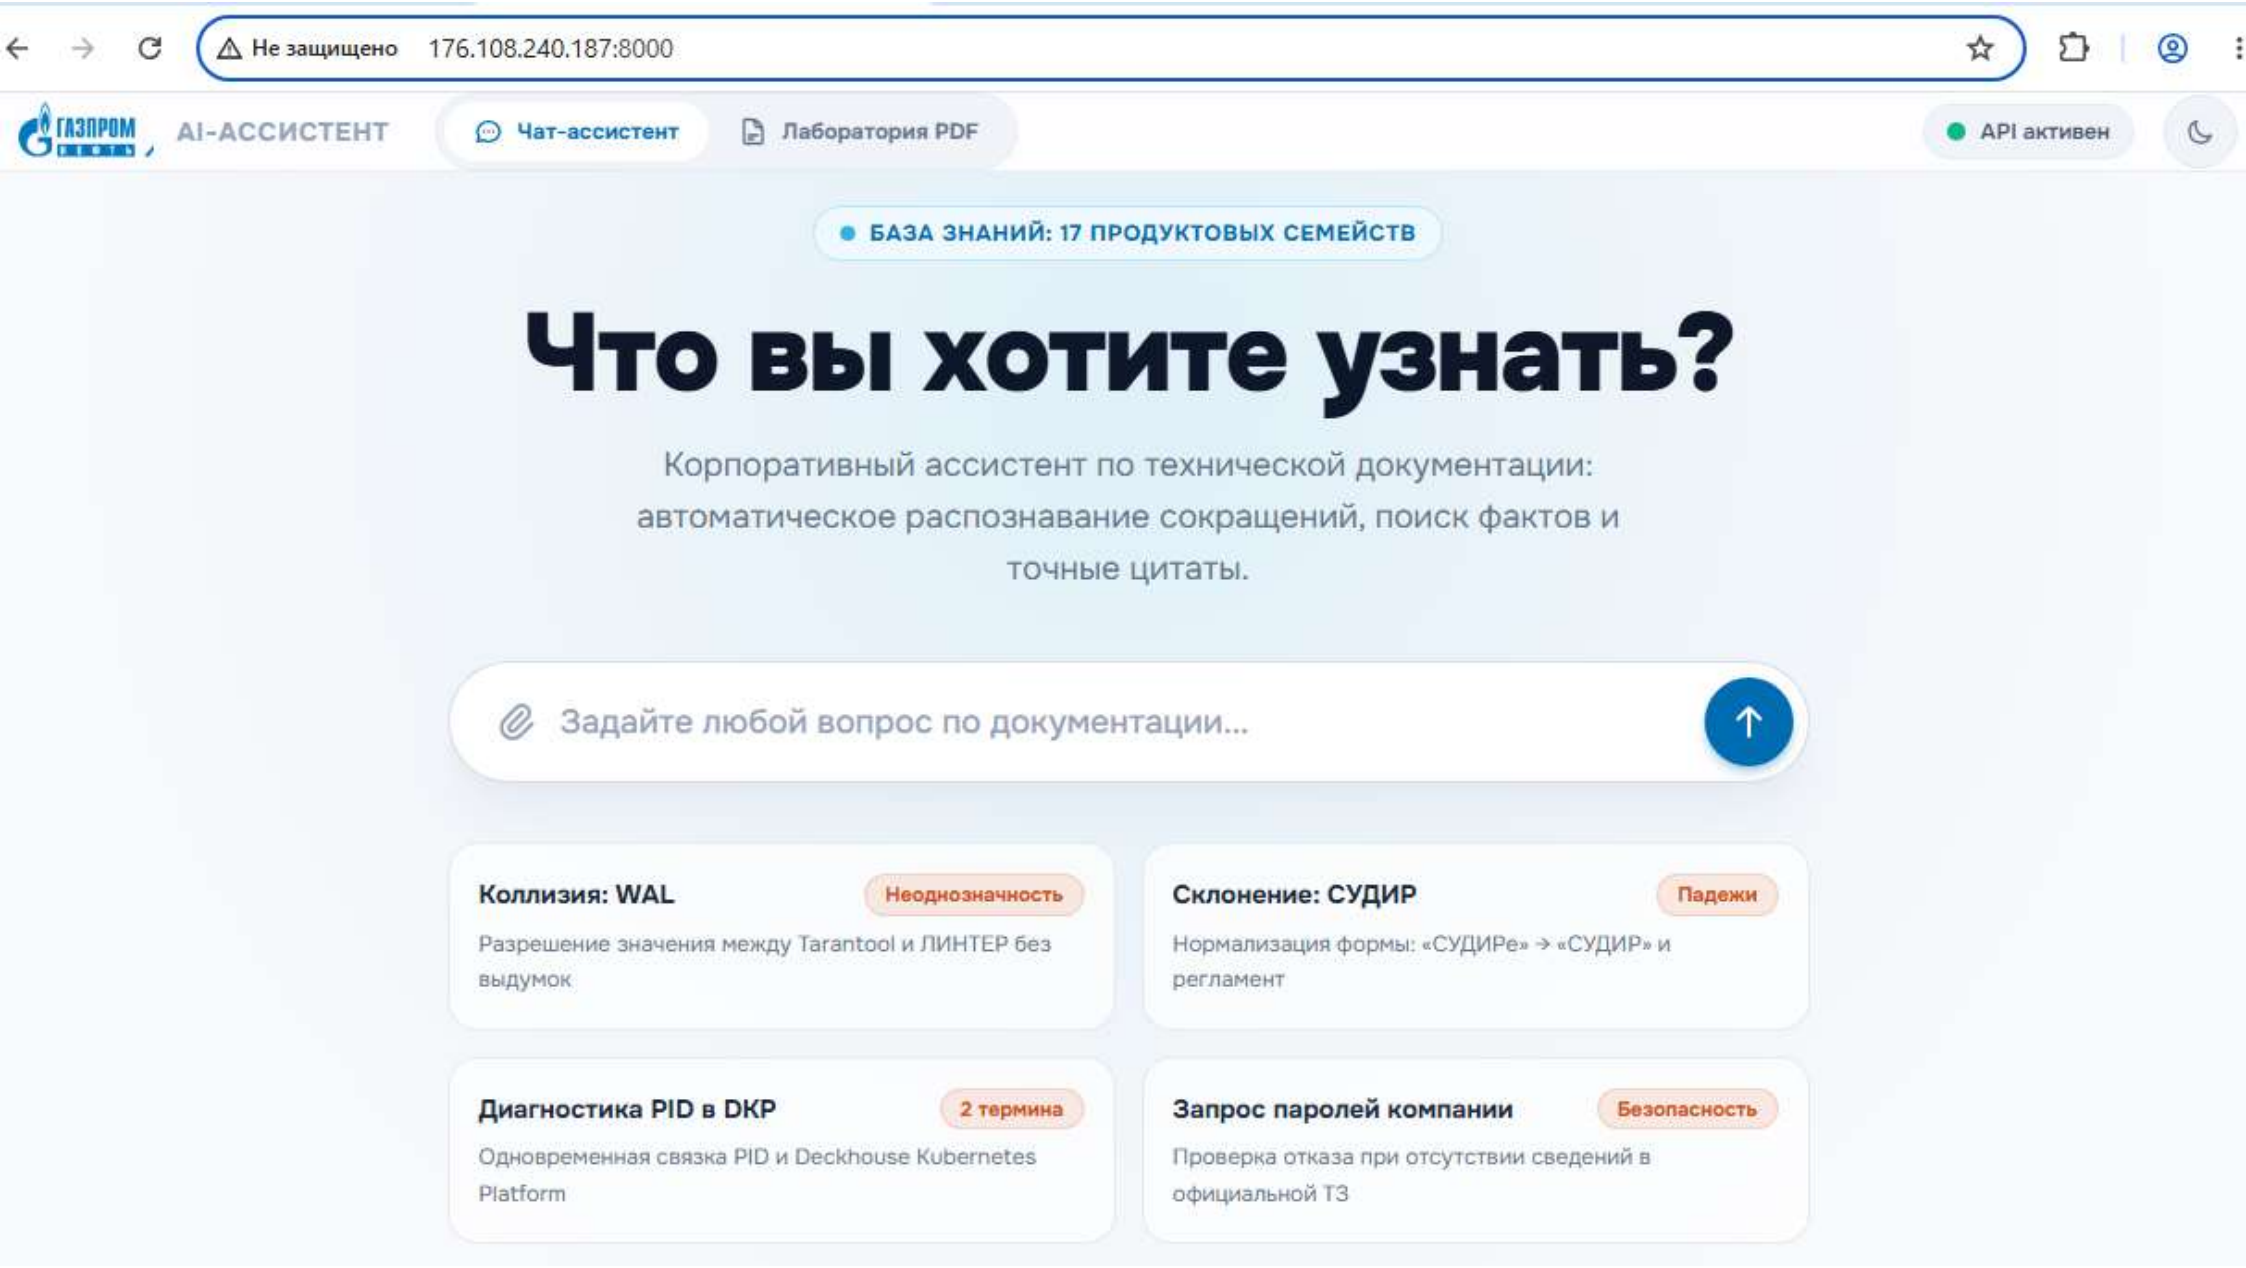
BM25 + векторы + страница определения, слияние RRF, фильтр по продукту

5

Ответ

LLM отвечает по найденным фрагментам со ссылками на документ и страницу

Ключевая идея: значение аббревиатуры выбирает код по словарю, а не модель. Модель получает уже выбранную расшифровку с цитатой-подтверждением и формулирует ответ.


Не защищено
176.108.240.187:8000
ГАЗПРОМ
AI-АССИСТЕНТ
Чат-ассистент
Лаборатория PDF
API активен
БАЗА ЗНАНИЙ: 17 ПРОДУКТОВЫХ СЕМЕЙСТВ
Что вы хотите узнать?
Корпоративный ассистент по технической документации: автоматическое распознавание сокращений, поиск фактов и точные цитаты.
Задайте любой вопрос по документации...
Коллизия: WAL
Неоднозначность
Разрешение значения между Tarantool и ЛИНТЕР без выдумок
Склонение: СУДИР
Падежи
Нормализация формы: «СУДИРе» → «СУДИР» и регламент
Диагностика PID в DKP
2 термина
Одновременная связка PID и Deckhouse Kubernetes Platform
Запрос паролей компании
Безопасность
Проверка отказа при отсутствии сведений в официальной ТЗ

ТЕХНОЛОГИИ

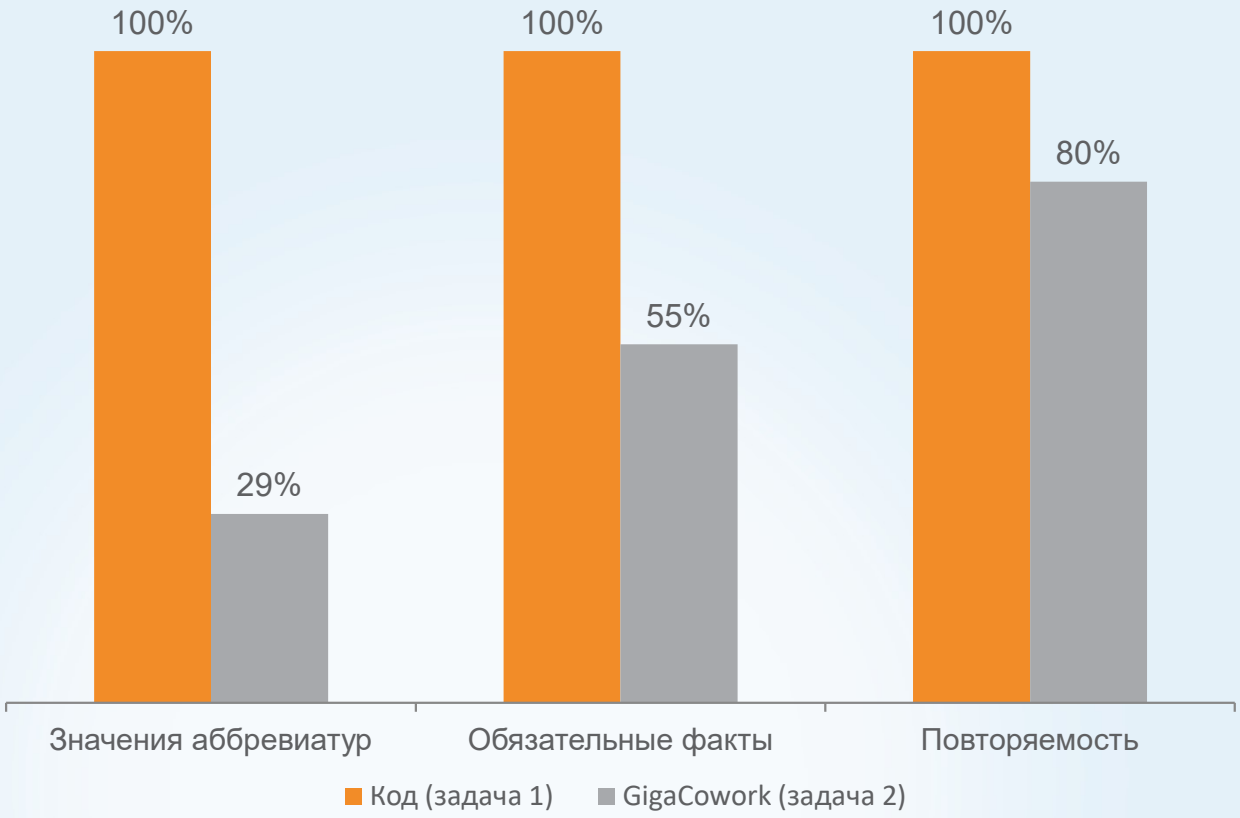
Стек в рамках ограничений хакатона

Компонент	Выбор	Почему
Генерация ответа	GigaChat-2 (Sber) или Qwen3.6-35B-A3B на cloud.ru	35B MoE — в пределах лимита 40B; провайдер переключается переменной окружения
Лексический поиск	BM25 по леммам (pymorphy3)	Находит точные ключи и параметры: -ux, shared-ip-key
Семантический поиск	multilingual-e5-small, ONNX, локально	118M параметров, работает на CPU, понимает перефразирование
Слияние	RRF + страница определения из словаря	Страница, где дана расшифровка, часто содержит и ответ
Сервис	FastAPI + Docker на BM Cloud.ru	Контракт openapi.yaml, запуск одной командой

Без LLM (ошибка API или LLM_PROVIDER=none) сервис не падает: ответ собирается из самых релевантных предложений найденных фрагментов.

РЕЗУЛЬТАТЫ

Код против GigaCowork на эталонных вопросах



12 с

среднее время ответа кода
(GigaCowork — 22,9 с)

21 / 21

значений аббревиатур выбрано верно,
включая оба WAL

x 100

ускорение в 100 раз
(с 20 минут до 12 секунд)

5 вопросов из evaluation__train.xlsx × 3 прогона; ответы сверены с «обязательными фактами» вручную. Лимит API — 90 с на запрос.

100% точность · 12.0 сек 17 систем в едином окне

Готов к пилотному внедрению в контур компании

Пилот на фокус-группе Service Desk (разгрузка первой линии)

Встраивание бота в корпоративный мессенджер eXpress (чтобы был под рукой в чате)

Подключение новых регламентов, обработка сканированных документов

